

Nom du jeu de données

Prenom Nom



## Remerciements

Résumé

# Table des matières

|          |                                                                                                                                                                                 |           |
|----------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                                                                                                                                             | <b>5</b>  |
| 1.1      | Contexte de l'étude . . . . .                                                                                                                                                   | 6         |
| 1.2      | Présentation des objectifs de l'étude . . . . .                                                                                                                                 | 6         |
| 1.3      | Présentation des variables . . . . .                                                                                                                                            | 6         |
| 1.3.1    | La variable cible . . . . .                                                                                                                                                     | 6         |
| 1.3.2    | Les variables et leurs type . . . . .                                                                                                                                           | 6         |
| 1.3.3    | Les données manquantes . . . . .                                                                                                                                                | 6         |
| <b>2</b> | <b>Présentation des graphiques adaptés</b>                                                                                                                                      | <b>7</b>  |
| 2.1      | Pour les variables continues : histogrammes ou boîtes à moustaches . . . . .                                                                                                    | 7         |
| 2.2      | Pour les variables discrètes : diagramme en bâtons . . . . .                                                                                                                    | 7         |
| 2.3      | Pour les variables qualitatives : diagramme en bâtons . . . . .                                                                                                                 | 7         |
| <b>3</b> | <b>Présentation des tests adaptés</b>                                                                                                                                           | <b>8</b>  |
| 3.1      | Indépendance entre variables qualitatives ou quantitatives discrètes (avec peu de modalités) : test du $\chi^2$ d'indépendance . . . . .                                        | 8         |
| 3.2      | Liaison entre une variable continue et une variable qualitative à 2 modalités . . . . .                                                                                         | 9         |
| 3.2.1    | Test d'égalité d'espérances pour échantillons indépendants . . . . .                                                                                                            | 9         |
| 3.3      | Si la variable qualitative plus de 2 modalités (par exemple 3 modalités), on va tester l'égalité des espérances dans les 3 groupes définis par la variable qualitative. . . . . | 10        |
| 3.4      | Liaison entre variables continues . . . . .                                                                                                                                     | 10        |
| 3.4.1    | Test d'indépendance de Kolmogorov-Smirnov. . . . .                                                                                                                              | 10        |
| 3.4.2    | Test de corrélation de Pearson . . . . .                                                                                                                                        | 10        |
| <b>4</b> | <b>Mise en oeuvre sur le jeu de données.</b>                                                                                                                                    | <b>12</b> |
| <b>5</b> | <b>Conclusion</b>                                                                                                                                                               | <b>13</b> |
| <b>A</b> | <b>Titre de la première annexe</b>                                                                                                                                              | <b>15</b> |
|          | <b>Bibliographie</b>                                                                                                                                                            | <b>17</b> |

# Chapitre 1

## Introduction


Dans l'article de Hao *et al.* (2018) ils utilisent ..... (Alaya, Lemler, Guilloux, and Allart 2018)

$$\begin{aligned} A &= \int_{-\infty}^{+\infty} \exp\left(-\frac{x^2}{2}\right) dx \\ &= \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}. \end{aligned} \tag{1.1}$$

La formule (1.1) se démontre à l'aide de ...

Comment insérer des images

Voici le graphe de deux densités :



- 1.1 Contexte de l'étude
- 1.2 Présentation des objectifs de l'étude
- 1.3 Présentation des variables
  - 1.3.1 La variable cible
  - 1.3.2 Les variables et leurs type
  - 1.3.3 Les données manquantes

## Chapitre 2

# Présentation des graphiques adaptés

- 2.1 Pour les variables continues : histogrammes ou boîtes à moustaches
- 2.2 Pour les variables discrètes : diagramme en bâtons
- 2.3 Pour les variables qualitatives : diagramme en bâtons

# Chapitre 3

## Présentation des tests adaptés

### 3.1 Indépendance entre variables qualitatives ou quantitatives discrètes (avec peu de modalités) : test du $\chi^2$ d'indépendance

Pour étudier la liaison entre deux variables quantitatives discrètes ou qualitatives, on utilise le test du chi-deux d'indépendance.

On souhaite donc tester

$$\begin{aligned}(H_0) : & \quad X \text{ et } Y \text{ sont indépendantes} \\(H_1) : & \quad X \text{ et } Y \text{ sont liées}\end{aligned}$$

soit aussi

$$\begin{aligned}(H_0) : & \quad \mathbb{P}(X = u_j \text{ et } Y = v_k) = \mathbb{P}(X = u_j)\mathbb{P}(Y = v_k) \quad \forall (j, k) \in \{1, \dots, J\} \times \{1, \dots, K\} \\(H_1) : & \quad \text{il existe } (j, k) \in \{1, \dots, J\} \times \{1, \dots, K\} \text{ tel que } \mathbb{P}(X = u_j \text{ et } Y = v_k) \neq \mathbb{P}(X = u_j)\mathbb{P}(Y = v_k).\end{aligned}$$

Nous allons estimer  $\mathbb{P}(X = u_j \text{ et } Y = v_k)$ ,  $\mathbb{P}(X = u_j)$  et  $\mathbb{P}(Y = v_k)$ , et comparer leurs estimateurs. On peut estimer, de manière naturelle  $\mathbb{P}(X = u_j \text{ et } Y = v_k)$ ,  $\mathbb{P}(X = u_j)$  et  $\mathbb{P}(Y = v_k)$ , respectivement par

$$\frac{N_{j,k}}{n} \quad ; \quad \frac{N_{j\bullet}}{n} \quad ; \quad \frac{N_{\bullet k}}{n}.$$

Sous  $(H_0)$ , les différences  $\frac{N_{j,k}}{n} - \frac{N_{j\bullet}}{n} \frac{N_{\bullet k}}{n}$  ne doivent être dues qu'aux fluctuations d'échantillonnage. On va donc comparer  $\frac{N_{j,k}}{n}$  et  $\frac{N_{j\bullet}}{n} \frac{N_{\bullet k}}{n}$ , ce qui revient à comparer les  $N_{j,k}$ , effectifs réels, aux  $\frac{N_{j\bullet} N_{\bullet k}}{n}$ , effectifs théoriques sous  $(H_0)$ .

Alors, la statistique de test,

$$T_n = \sum_{j=1}^J \sum_{k=1}^K \frac{\left( N_{j,k} - \frac{N_{j\bullet} N_{\bullet k}}{n} \right)^2}{\frac{N_{j\bullet} N_{\bullet k}}{n}}.$$

La loi de  $T_n$  sous  $(H_0)$  est donnée par le résultat suivant

Proposition Si les conditions suivantes sont satisfaites

- $n$  est grand
- les classes constituent un système complet d'événements, c'est-à-dire toute valeur théorique appartient à une et une seule classe
- les effectifs théoriques par classe sont suffisamment importants  $\frac{N_{j\bullet} N_{\bullet k}}{n} \geq 5 \quad \forall (j, k) \in \{1, \dots, J\} \times \{1, \dots, K\}$ .

Alors, sous  $(H_0)$

$$T_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}, H_0} \chi^2((J-1)(K-1)).$$

Pour un test de niveau  $\alpha$ , on impose  $\mathbb{P}_{H_0}(\text{rejeter } H_0) \leq \alpha$ . On rejette  $(H_0)$  quand  $T_n$  prend de grandes valeurs. Ainsi,  $ZR_\alpha = \{T_n \geq c_\alpha\}$  avec  $c_\alpha$  est tel que  $\mathbb{P}(\chi^2((J-1)(K-1)) \geq c_\alpha) = \alpha$ . On en déduit la règle de décision : si  $T_n > c_\alpha$ , on rejette  $(H_0)$ , sinon on ne rejette pas  $(H_0)$  au niveau  $\alpha$ .

Remarques

1. S'il existe une classe, telle que l'effectif théorique est inférieur à 5, alors on regroupe deux (ou plus) classes. Pour voir les classes à regrouper utiliser `chisq.test(V1, V2)$expected`.
2. Si les variables n'ont que 2 modalités, vous ne pouvez pas faire de regroupement de classe. Dans ce cas, utiliser le test de Fisher exact. **La commande R sera `fisher.test`.**
3. Il y a  $(J - 1)(K - 1)$  nombre de classes – nombre de paramètres estimés – 1 degrés de liberté. Sous  $(H_0)$ ,  $\mathbb{P}(X = u_i \text{ et } Y = v_j) = \mathbb{P}(X = u_j)\mathbb{P}(Y = v_k)$ , donc les  $\mathbb{P}(X = u_i \text{ et } Y = v_j)$  se calculent à partir des  $\mathbb{P}(X = u_j)$  et des  $\mathbb{P}(Y = v_k)$ . De plus  $\sum_{j=1}^J \mathbb{P}(X = u_j) = 1$ , il suffit d'estimer  $J - 1$   $\mathbb{P}(X = u_j)$ ; de même  $\sum_{k=1}^K \mathbb{P}(Y = v_k) = 1$ , il suffit d'estimer  $K - 1$   $\mathbb{P}(Y = v_k)$ . Il y a donc en tout,  $(J - 1) + (K - 1) = J + K - 2$  paramètres à estimer. Le nombre de classes étant égal à  $I \times l$ , il y a donc  $JK - (J + K - 2) - 1 = JK - J - K + 1 = (J - 1)(K - 1)$  degrés de liberté.

La commande R sera `chisq.test`

## 3.2 Liaison entre une variable continue et une variable qualitative à 2 modalités

### 3.2.1 Test d'égalité d'espérances pour échantillons indépendants

(à programmer ou test de Student `t.test(X, Y, var.equal = FALSE)` dans le cas gaussien) [`shapiro.test` à utiliser avant pour vérifier si les variables sont gaussiennes.] Le test de Shapiro est inutile si la taille de l'échantillon est importante

Considérons  $X_1, \dots, X_{n_1}$ ,  $n_1$  variables aléatoires i.i.d. de loi  $P_X$  et  $Y_1, \dots, Y_{n_2}$ ,  $n_2$  variables aléatoires i.i.d. de loi  $P_Y$ , avec  $(X_1, \dots, X_{n_1})$  et  $(Y_1, \dots, Y_{n_2})$ , indépendants. On souhaite comparer les lois (ou les espérances) des  $X_i$  et des  $Y_i$  sont les mêmes. Nous disposons de trois tests

- Tests de comparaison d'espérances (test de Welsch)  
La statistique de test à utiliser est

$$T_{n_X, n_Y} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_Y^2}{n_Y}}},$$

avec

$$S_X^2 = \frac{1}{n_X - 1} \sum_{i=1}^{n_X} (X_i - \bar{X})^2 \text{ et } S_Y^2 = \frac{1}{n_Y - 1} \sum_{i=1}^{n_Y} (Y_i - \bar{Y})^2.$$

On peut montrer que sous  $H_0$ ,  $T_{n_X, n_Y} \xrightarrow[n_X \rightarrow +\infty, n_Y \rightarrow +\infty]{\mathcal{L}, H_0} \mathcal{N}(0, 1)$ . On rejette  $H_0$  quand  $|T_{n_X, n_Y}| \geq u_\alpha$  où  $u_\alpha$  est le quantile d'ordre  $1 - \alpha/2$  de la loi  $\mathcal{N}(0, 1)$ . On rejette  $(H_0)$  pour des grandes valeurs de la statistique de test.

- Test de Kolmogorov Smirnov de comparaison de 2 échantillons. **La commande R sera `ks.test`** Considérons  $X_1, \dots, X_{n_X}$ ,  $n_X$  variables aléatoires i.i.d. continues de loi  $P_X$  et  $Y_1, \dots, Y_{n_Y}$ ,  $n_Y$  variables aléatoires i.i.d. continues de loi  $P_Y$ , avec  $(X_1, \dots, X_{n_X})$  et  $(Y_1, \dots, Y_{n_Y})$ , indépendants. On souhaite savoir si les lois des deux variables aléatoires sont les mêmes.

$$(H_0) : F_X = F_Y \text{ contre } (H_0) : F_X \neq F_Y.$$

La statistique de test est donnée par

$$\sqrt{\frac{n_X n_Y}{n_X + n_Y}} \sup_{x \in \mathbb{R}} |\hat{F}_{n_X}(x) - \hat{G}_{n_Y}(x)|,$$

où

$$\hat{F}_{n_X}(x) = \frac{1}{n_X} \sum_{i=1}^{n_X} \mathbb{I}_{X_i \leq x} \text{ et } \hat{G}_{n_Y}(x) = \frac{1}{n_Y} \sum_{i=1}^{n_Y} \mathbb{I}_{Y_i \leq x}.$$

Les quantités  $\hat{F}_{n_X}(x)$  et  $\hat{G}_{n_Y}(x)$  sont des estimateurs de  $F_X$  et  $G_Y$ .

— Test de la somme des rangs de Wilcoxon (ou Mann-Whitney). *cortest(X, Y)*

Considérons  $X_1, \dots, X_{n_1}$ ,  $n_1$  variables aléatoires i.i.d. de loi  $P_X$  et  $Y_1, \dots, Y_{n_2}$ ,  $n_2$  variables aléatoires i.i.d. de loi  $P_Y$ , avec  $(X_1, \dots, X_{n_1})$  et  $(Y_1, \dots, Y_{n_2})$ , indépendants. On cherche à savoir si les variables  $Y_i$  ont tendance à prendre des plus grandes valeurs que les  $X_i$ . Notons  $Med(Y - X)$  la médiane de  $Y_i - X_i$ . Pour répondre à la questions on peut tester

$$(H_0) : Med(Y - X) = 0 \text{ contre } (H_1) : Med(Y - X) \neq 0.$$

La fonction  $R$  dans le package *robustTest* est : *wilcoxtest*.

### 3.3 Si la variable qualitative plus de 2 modalités (par exemple 3 modalités), on va tester l'égalité des espérances dans les 3 groupes définis par la variable qualitative.

La commande  $R$  sera *oneway.test* On note  $X$  le poids des bébés chez les mères telles que RACE = white On note  $Y$  le poids des bébés chez les mères telles que RACE = black On note  $Z$  le poids des bébés chez les mères telles que RACE = other L'hypothèse  $H_0 : \mathbb{E}(X) = \mathbb{E}(Y) = \mathbb{E}(Z)$ ; L'hypothèse  $H_1$  est il existe un couple parmi,  $X, Y, Z$  pour lequel les espérances sont différentes.

## 3.4 Liaison entre variables continues

### 3.4.1 Test d'indépendance de Kolmogorov-Smirnov.

La commande  $R$  sera *indepctest.test*.

Considérons des couples  $(X_1, Y_1) \dots (X_n, Y_n)$   $n$  copies indépendantes d'un couple  $(X, Y)$  de variables aléatoires réelles. Supposons de plus que les variables  $X$  et  $Y$  sont continues. On souhaite tester

$$(H_0) : X \text{ et } Y \text{ sont indépendantes contre } (H_1) : X \text{ et } Y \text{ ne sont pas indépendantes.}$$

L'hypothèse nulle revient donc à écrire que pour tous  $s$  et  $t$  dans  $\mathbb{R}$ ,

$$\text{pour tous } t \in \mathbb{R} \text{ et tous } s \in \mathbb{R} \mathbb{P}(X \leq s \cap Y \leq t) = \mathbb{P}(X \leq s)\mathbb{P}(Y \leq t).$$

La statistique de test sera alors

$$T_n = \sqrt{n} \sup_{s, t \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{X_i \leq s, Y_i \leq t} - F_{n,X}(s)F_{n,Y}(t) \right|,$$

où

$$F_{n,X}(s) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{X_i \leq s}, \text{ et } F_{n,Y}(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{Y_i \leq t}.$$

On rejette  $(H_0)$  pour des grandes valeurs de  $T_n$ .

### 3.4.2 Test de corrélation de Pearson

On peut également tester la non corrélation entre deux variables continues. On utilisera le test de corrélation Pearson.

Soient  $(X_1, Y_1) \dots (X_n, Y_n)$  des couples de variables aléatoires quantitatives indépendantes et identiquement distribuées. On suppose que les variables  $X_i$  et  $Y_i$  possèdent un moment d'ordre 2 et on note  $\mu_X$  l'espérance des  $X_i$  et  $\mu_Y$  l'espérance des  $Y_i$ . On note  $\rho$  le coefficient de corrélation entre  $X_i$  et  $Y_i$ . On souhaite tester

$$(H_0) : \rho = 0 \text{ contre } \rho \neq 0, \text{ où } \rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

La statistique de test à utiliser est la suivante

$$T_n = \frac{\sum_{k=1}^n (X_k - \bar{X}_k)(Y_k - \bar{Y}_k)}{\sqrt{\sum_{k=1}^n (Z_k - \bar{Z}_k)^2}}, \text{ où } Z_k = (X_k - \bar{X}_k)(Y_k - \bar{Y}_k).$$

Sous l'hypothèse  $0 < \mathbb{E}[(X_i - \mu_X)^2(Y_i - \mu_Y)^2] < \infty$ , on peut montrer que

$$T_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}, H_0} \mathcal{N}(0, 1).$$

La zone de rejet est donc

$$R_{n,\alpha} = \{|T_n| > u_\alpha\}$$

où  $u_\alpha$  est le quantile d'ordre  $1 - \alpha/2$  de la loi  $\mathcal{N}(0, 1)$ .

**La commande  $R$  sera *cortest*.**

## Chapitre 4

Mise en oeuvre sur le jeu de données.

**Chapitre 5**

**Conclusion**



**Annexe A**

**Titre de la première annexe**



# Références

- Alaya, M. Z., S. Lemler, A. Guilloux, and T. Allart (2018, June). High-dimensional time-varying Aalen and Cox models. working paper or preprint.
- Hao, N., Y. Feng, and H. H. Zhang (2018). Model selection for high-dimensional quadratic regression via regularization. *Journal of the American Statistical Association* 113(522), 615–625.