

Feuille de route — Projet Statistiques avec R

Étude du dataset *Palmer Penguins* (Adelie vs Gentoo) — classification binaire
L3 Mathématiques & Applications · Université d'Évry Paris-Saclay
Livrables : rapport LaTeX ≤ 25 p. · soutenance Beamer ≤ 15 slides

» Idée directrice (à garder en tête tout le rapport)

Ce jeu de données présente une **quasi-séparation complète** entre les deux espèces : les Gentoo sont morphométriquement très distincts des Adelie. **Conséquence statistique** : tous les tests de liaison entre espèces et une variable morphométrique rejettent H_0 avec des p-values dérisoires ($< 10^{-60}$). Un rapport **solide** ne se contente donc PAS d'aligner des p-values ; en s'appuyant uniquement sur les outils du cours, il doit (1) **décrire l'ampleur** des écarts (moyennes par groupe, IC des différences renvoyés par t-test, boxplots sans recouvrement), (2) **contraster** avec le seul test non-significatif (species $\times$ year), (3) **confirmer par un test non-paramétrique** (Wilcoxon, KS) ne supposant pas la gaussianité, (4) **analyser la structure** de corrélation des variables continues, dont le **paradoxe de Simpson**. C'est là qu'est la valeur scientifique.

0. Le dataset en chiffres (vérifié)

Variable	Type	Description / valeurs observées (moy. $\pm$ éc.-type)	Rôle
species	Qual. binaire	Adelie 151 · Gentoo 123 (55%/45%)	CIBLE
island	Qual. 3 mod.	Biscoe 167 · Dream 56 · Torgersen 51	Explicative
bill_length_mm	Continue	Adelie 38.8 ± 2.7 · Gentoo 47.5 ± 3.1	Explicative
bill_depth_mm	Continue	Adelie 18.3 ± 1.2 · Gentoo 15.0 ± 1.0	Explicative
flipper_length_mm	Continue	Adelie 190 ± 6.5 · Gentoo 217 ± 6.5	Explicative
body_mass_g	Continue	Adelie 3701 ± 459 · Gentoo 5076 ± 504	Explicative
year	Discrète 3 mod.	2007:83 · 2008:96 · 2009:95	Secondaire

274 observations, 0 donnée manquante. Dataset déjà nettoyé (la variable sex du dataset Palmer complet a été retirée, ainsi que l'espèce Chinstrap).

1. Budget de pages (rapport ≤ 25 p.) et plan

Chapitre	Contenu	Pages
Titre + Résumé + TOC	Page de garde Évry, résumé 8 lignes, sommaire	2
1. Introduction	Contexte biologique, objectifs, variables, données manquantes	2–3
2. Graphiques descriptifs	Bâtons (species, island), boxplots facettés, scatter Simpson, pairs plot	4–5
3. Rappels théoriques	Chi2, Welch (justifié par TLC), Pearson, test d'indépendance	4–5
4. Mise en œuvre	Résultats commentés + tableau de synthèse (p-value + ampleur)	6–7
5. Conclusion	Synthèse, limites (séparation), perspective (LDA/régression log.)	1–2
Annexe + Biblio	Code R commenté, références	2–3

Conseil de mise en page : regrouper les 4 boxplots en une **seule figure facettée** (facet_wrap) et utiliser un **pairs plot** (GGally) qui condense distributions + corrélations + séparation en une image. On gagne 3–4 pages sans perdre d'information.

2. Préparation des données (Chap. 1)

```
library(dplyr); library(ggplot2); library(GGally); library(knitr)
```

```
penguins <- read.csv("penguins_binary_classification.csv")
glimpse(penguins); summary(penguins)
sapply(penguins, function(j) sum(is.na(j))) # => 0 partout
penguins <- mutate(penguins, species=factor(species),
                    island=factor(island), year=factor(year))
attach(penguins, warn.conflicts=FALSE)
```

3. Graphiques (Chap. 2) — choix justifiés

Graphique	Variables	Pourquoi (rôle dans l'argumentation)
Diagramme bâtons	species	Montrer l'équilibre 55/45 de la cible
Bâtons empilés/dodge	island × species	Révéler que Gentoo = Biscoe uniquement
Boxplots facettés	4 continues × species	Visualiser la séparation (1 figure)
Scatter coloré	bill_length × bill_depth	ILLUSTRER le paradoxe de Simpson
Pairs plot (ggpairs)	toutes continues	Distributions + corrélations + séparation

Code-clé — scatter du paradoxe de Simpson (le graphique le plus important) :

```
ggplot(penguins, aes(bill_length_mm, bill_depth_mm, color=species)) +
  geom_point(alpha=.7) +
  geom_smooth(method="lm", se=FALSE) + # tendances PAR espèce
  geom_smooth(aes(group=1), method="lm", se=FALSE,
              color="black", linetype="dashed") + # tendance GLOBALE
  labs(title="Paradoxe de Simpson : bec long vs bec profond") + theme_bw()

# Boxplots facettés (1 figure pour les 4 variables)
library(tidyr)
penguins %>% pivot_longer(c(bill_length_mm, bill_depth_mm,
                             flipper_length_mm, body_mass_g)) %>%
  ggplot(aes(species, value, fill=species)) + geom_boxplot() +
  facet_wrap(~name, scales="free_y") + theme_bw()
```

4. Tests statistiques — pertinence et résultats attendus

4.1 Récapitulatif des tests retenus (avec résultats vérifiés sur les données)

Liaison	Test	Justification du choix	Résultat attendu
species × island	Chi2 d'indép.	2 qual., eff. theo. tous >=5	p=9e-32 — liées
species × year	Chi2 d'indép.	2 qual., effectifs >=5	p = 0.64 — NON lié
species × bill_length	Welch	continu × qual. binaire	p<1e-67 (ecart +8.7 mm)
species × bill_depth	Welch	idem	p<1e-73 (ecart -3.3 mm)
species × flipper_len	Welch	idem	p<1e-99 (ecart +27 mm)
species × body_mass	Welch	idem	p<1e-64 (ecart +1375 g)
continue × continue	Pearson + indép.	corrélation linéaire + indép.	voir 4.4

4.2 Chi2 species × island — CORRECTION importante

```
chisq.test(species, island, correct=FALSE)
chisq.test(species, island)$expected # min = 22.9 => tous >= 5
chisq.test(species, island)$observed # Gentoo : Biscoe uniquement
```

!! Contrairement au cas birthwt : ici les effectifs théoriques sont **tous ≥ 5** (le plus petit vaut 22.9). Le chi-deux est donc **parfaitement valide** et le test de Fisher n'est **pas** requis. On peut le mentionner en robustesse (présence de zéros structurels : aucun Gentoo hors Biscoe), mais sans en faire le test principal.

4.3 Welch — et sa justification théorique (lien TD4 LGN/TLC)

```
t.test(bill_length_mm ~ species, var.equal=FALSE) # idem pour les 4
# t.test renvoie AUTOMATIQUEMENT l'IC de la différence des moyennes
# Décrire l'ampleur avec des stats du cours :
aggregate(bill_length_mm ~ species, FUN=mean) # moyennes par groupe
```

Justification de rigueur : la validité asymptotique de la statistique de Welch (convergence vers $N(0,1)$) repose sur le **Théorème Central Limite** — exactement l'objet du TD4. Avec $n_1=151$ et $n_2=123$, l'approximation gaussienne est excellente. **Ne pas surutiliser Shapiro** : à grand n il rejette la normalité sur des écarts négligeables (ici $p=0.002$ pour les nageoires Gentoo) sans que cela invalide Welch. Mentionner Shapiro pour la forme, mais s'appuyer sur le TLC pour justifier.

Décrire l'ampleur (outils du cours) : plutôt qu'une taille d'effet hors-programme, reporter l'**intervalle de confiance de la différence des moyennes** (sortie automatique de `t.test`) et les **moyennes par groupe** ; les boxplots sans recouvrement rendent la séparation visible. **Robustesse** : confirmer par un test non-paramétrique ne supposant pas la gaussianité — Wilcoxon-Mann-Whitney (`wilcoxtest`, `robusTest`) sur l'égalité des médianes, ou KS à 2 échantillons (`ks.test`) sur l'égalité des lois $F_X=F_Y$. Ces tests figurent tous au programme (rapport-exemple §3.2).

4.4 Corrélations entre variables continues + paradoxe de Simpson

```
cor.test(flipper_length_mm, body_mass_g) # r=+0.88
cor.test(bill_length_mm, flipper_length_mm) # r=+0.87
# --- Paradoxe de Simpson (resultat phare) ---
cor.test(bill_length_mm, bill_depth_mm) # GLOBAL : r=-0.55
by(penguins, species, function(d)
  cor(d$bill_length_mm, d$bill_depth_mm)) # Adelie +0.39 / Gentoo +0.64
# Test d'indépendance general (programme, code de la prof) :
# indeptest(bill_length_mm, bill_depth_mm) du package robusTest
```

Le résultat à mettre en avant : globalement, longueur et profondeur du bec sont corrélées **négativement** ($r = -0.55$) ; mais **au sein de chaque espèce**, la corrélation est **positive** (+0.39 et +0.64). C'est un paradoxe de Simpson : la variable `species` est une variable confondante. Excellent point de discussion mathématique.

4.5 Lire les résultats dans un contexte de quasi-séparation

- **Significativité ≠ ampleur** : avec n grand et des groupes très séparés, toutes les p -values sont minuscules. Ne pas les sur-interpréter — ce n'est pas la « force » du lien mais son existence.
- **Décrire l'ampleur avec le cours** : moyennes par groupe + **IC de la différence** (sortie de `t.test`) ; boxplots sans recouvrement.
- **Hiérarchiser** : comparer les écarts standardisés « à la main » (écart de moyennes rapporté à l'écart-type) si l'on veut classer les variables — `flipper_length` se détache.
- *Pour information* : il existe des mesures de « taille d'effet » qui chiffrent l'ampleur d'un écart, mais elles sortent du cadre de ce cours — inutile de les inclure dans le rapport.

4.6 Tableau de synthèse à produire (Chap. 4)

```
res <- data.frame(
  Liaison=c("species×island", "species×year", "species×bill_len",
            "species×bill_depth", "species×flipper", "species×mass"),
  Test=c("Chi2", "Chi2", "Welch", "Welch", "Welch", "Welch"),
  p_value=c("9e-32", "0.64", "<1e-67", "<1e-73", "<1e-99", "<1e-64"),
  Ampleur=c("Gentoo=Biscoe", "reparti", "+8.7 mm", "-3.3 mm",
            "+27 mm", "+1375 g"),
  Decision=c("Liees", "Independantes", rep("Liees", 4)))
kable(res, caption="Synthese des tests (alpha=5%)")
```

5. Conclusion (Chap. 5) — structure

- **Réponse à l'objectif** : les 4 variables morphométriques distinguent fortement les espèces ; `flipper_length` présente le plus grand écart relatif (la plus discriminante).
- **Géographie** : `island` liée à l'espèce (Gentoo = Biscoe).
- **Contre-exemple** : `year` indépendante de l'espèce → l'échantillonnage n'est pas biaisé temporellement.
- **Paradoxe de Simpson** sur les dimensions du bec : effet confondant de l'espèce.

- **Limites** : séparation quasi-complète (p-values peu informatives, d'où l'importance de décrire l'ampleur des écarts) ; pas de variable sexe ; 2 espèces seulement.
- **Perspective** : ces résultats fondent un classifieur binaire (régression logistique / analyse discriminante linéaire) — transition naturelle vers le ML, hors périmètre de ce projet de tests.

6. Plan de soutenance Beamer (≤ 15 slides)

#	Slide	Contenu
1	Titre	Sujet, nom, Évry, date
2	Contexte & objectif	Palmer Station ; distinguer Adelie/Gentoo par des tests
3	Le dataset	274 obs, 7 variables, 0 NA, variable cible
4	Cible & îles	Bâtons species + bâtons island $\times$ species (Gentoo=Biscoe)
5	Morphométrie	Boxplots facettés : la séparation saute aux yeux
6	Méthodo des tests	Tableau : quel test pour quel couple de variables
7	Chi2 species $\times$ island	Résultat + table de contingence ; pourquoi pas Fisher
8	Chi2 species $\times$ year	Le test qui NE rejette PAS (contraste)
9	Welch + TLC	Comparaison des moyennes ; justif. par le TLC (TD4)
10	Ampleur & robustesse	Écarts de moyennes + IC ; Wilcoxon/KS confirment Welch
11	Corrélations	Pairs plot / matrice : structure des continues
12	Paradoxe de Simpson	Le scatter avec droites par espèce vs globale
13	Synthèse	Tableau récap p-value + ampleur + décision
14	Conclusion & limites	Séparation, perspective LDA/régression
15	Merci / Questions	+ slide(s) backup : code R, sorties Shapiro, Wilcoxon/KS

Astuce Beamer : garder 2–3 *slides backup* (après le « Merci ») avec le code R, les sorties Shapiro et les tests de robustesse (Wilcoxon, KS), pour répondre au jury sans surcharger.

7. Ressources & packages R

Besoin	Ressource / package
EDA + chi-deux + ggpairs (modèle R)	bloggers.com/2020/07/basic-data-analysis-with-palmerpenguins
EDA visuelle	kaggle.com/code/alabuda/classification-and-eda-palmer-penguins
Analyse complète + interprétation	RStudio Pubs Data 622 (régression logistique)
Référence à citer (biblio)	Horst, Hill & Gorman (2020/2022), site + R Journal RJ-2022-020
Stats descriptives + IC	base R : aggregate, tapply ; t.test (IC des différences)
Tests robustes	wilcox.test, ks.test (base) ; robustTest (indeptest)
Modèle de code/structure	mails de la prof (birthwt) + exemple_rapport_stat_avec_R.pdf

8. Checklist qualité avant rendu

- [] species, island, year en factor ; vérif 0 NA
- [] Chi2 : effectifs théoriques (\$expected) montrés et commentés
- [] Welch : var.equal=FALSE ; validité justifiée par le TLC (pas par Shapiro)
- [] IC des différences (t.test) + moyennes par groupe reportés

- [] Au moins un test non-paramétrique de robustesse (Wilcoxon ou KS)
- [] Paradoxe de Simpson illustré (scatter) ET chiffré (corrélations par groupe)
- [] Test species×year présenté comme contre-exemple (non-rejet)
- [] Significativité distinguée de l'ampleur (commentaire sur la quasi-séparation)
- [] Tableau de synthèse kable (test + p-value + ampleur + décision)
- [] Toutes figures titrées, axes nommés ; boxplots regroupés (facet)
- [] Rapport ≤ 25 p. · Beamer ≤ 15 slides · biblio présente · .Rmd/.tex compilable