

Palmer Penguins : Classification binaire Adelie vs Gentoo

Prénom Nom

L3 Mathématiques & Applications
Université d'Évry Paris-Saclay

Projet de Statistiques avec R
Année universitaire 2025–2026

Remerciements

Je remercie ma professeure de statistiques pour son encadrement tout au long de ce projet, ainsi que pour la mise à disposition du jeu de données et des outils méthodologiques utilisés dans cette étude. Je remercie également Allison Horst, Alison Hill et Kristen Gorman pour la collecte et la publication du jeu de données *Palmer Penguins*, qui constitue une ressource pédagogique de grande qualité.

Résumé

Ce rapport présente une analyse statistique du jeu de données *Palmer Penguins*, restreint aux espèces Adelie et Gentoo (274 observations, 7 variables, aucune donnée manquante). L'objectif est d'étudier les liaisons entre la variable cible **species** et les variables explicatives à l'aide de tests adaptés : test du χ^2 d'indépendance pour les variables qualitatives, test de Welch pour les variables continues, et tests de corrélation de Pearson pour les liaisons entre variables continues. Les résultats montrent que les quatre variables morphométriques distinguent fortement les deux espèces, avec une quasi-séparation complète. Le paradoxe de Simpson sur les dimensions du bec constitue un résultat remarquable. Seule la variable **year** est indépendante de l'espèce.

Table des matières

Remerciements	1
Résumé	2
1 Introduction	5
1.1 Contexte de l'étude	5
1.2 Présentation des objectifs de l'étude	5
1.3 Présentation des variables	5
1.3.1 La variable cible	5
1.3.2 Les variables et leur type	6
1.3.3 Les données manquantes	6
2 Présentation des graphiques adaptés	7
2.1 Pour les variables qualitatives : diagramme en bâtons	7
2.2 Pour les variables discrètes : diagramme en bâtons	8
2.3 Pour les variables continues : boîtes à moustaches	8
2.4 Nuage de points et paradoxe de Simpson	9
2.5 Pairs plot	10
2.6 Matrice de corrélation	11
3 Présentation des tests adaptés	13
3.1 Indépendance entre variables qualitatives : test du χ^2 d'indépendance . . .	13
3.2 Liaison entre une variable continue et une variable qualitative à 2 modalités	14
3.2.1 Test d'égalité d'espérances pour échantillons indépendants (test de Welch)	14
3.2.2 Test de Kolmogorov-Smirnov à 2 échantillons	14
3.2.3 Test de la somme des rangs de Wilcoxon (Mann-Whitney)	15
3.3 Liaison entre variables continues	15
3.3.1 Test de corrélation de Pearson	15
3.3.2 Test d'indépendance de Kolmogorov-Smirnov	15
4 Mise en œuvre sur le jeu de données	16
4.1 Test du χ^2 : <code>species</code> $\times$ <code>island</code>	16
4.2 Test du χ^2 : <code>species</code> $\times$ <code>year</code>	16
4.3 Tests de Welch : <code>species</code> $\times$ variables continues	17
4.4 Tests non paramétriques de robustesse	18
4.5 Corrélations entre variables continues et paradoxe de Simpson	18
4.6 Tableau de synthèse	19

5 Conclusion	20
A Code R commenté	21

Chapitre 1

Introduction

1.1 Contexte de l'étude

Le jeu de données *Palmer Penguins* a été collecté par la chercheuse Kristen Gorman à la station Palmer en Antarctique entre 2007 et 2009 [1]. Il contient des mesures morphométriques de trois espèces de manchots : Adelie, Chinstrap et Gentoo. Dans le cadre de ce projet, nous travaillons sur une version restreinte à deux espèces — Adelie et Gentoo — afin de mener une étude de classification binaire. La variable **sex** a été retirée et l'espèce Chinstrap exclue du jeu de données.

Ce jeu de données présente une caractéristique remarquable : les Gentoo sont morphométriquement très distincts des Adelie. Conséquence statistique : tous les tests de liaison entre **species** et une variable morphométrique rejettent H_0 avec des p -values extrêmement faibles. Un rapport solide ne se contente donc pas d'aligner des p -values ; il doit décrire l'*ampleur* des écarts, contraster avec le test non significatif (**species** $\times$ **year**), confirmer par des tests non paramétriques, et analyser la structure de corrélation des variables continues.

1.2 Présentation des objectifs de l'étude

L'objectif principal de cette étude est de déterminer, à l'aide des outils statistiques du cours, quelles variables sont liées à l'espèce de manchot. Plus précisément, nous souhaitons :

1. identifier les variables significativement liées à **species** ;
2. quantifier l'ampleur des différences entre les deux groupes ;
3. étudier la structure de corrélation entre les variables continues ;
4. mettre en évidence le paradoxe de Simpson sur les dimensions du bec.

1.3 Présentation des variables

1.3.1 La variable cible

La variable cible est **species**, variable qualitative binaire prenant les modalités Adelie (151 observations, soit 55 %) et Gentoo (123 observations, soit 45 %). La répartition est relativement équilibrée.

1.3.2 Les variables et leur type

Le jeu de données comporte 7 variables dont le détail est donné dans le tableau 1.1.

TABLE 1.1 – Description des variables du jeu de données.

Variable	Type	Description	Rôle
species	Qual. binaire	Adelie (151) / Gentoo (123)	Cible
island	Qual. 3 mod.	Biscoe (167), Dream (56), Torgersen (51)	Explicative
bill_length_mm	Continue	Longueur du bec (mm)	Explicative
bill_depth_mm	Continue	Profondeur du bec (mm)	Explicative
flipper_length_mm	Continue	Longueur des nageoires (mm)	Explicative
body_mass_g	Continue	Masse corporelle (g)	Explicative
year	Discrète, 3 mod.	2007 (83), 2008 (96), 2009 (95)	Secondaire

Le tableau 1.2 présente les statistiques descriptives des variables continues, par espèce.

TABLE 1.2 – Statistiques descriptives des variables continues par espèce (moyenne $\pm$ écart-type).

Variable	Adelie ($n_1 = 151$)	Gentoo ($n_2 = 123$)
bill_length_mm	$38,8 \pm 2,7$	$47,5 \pm 3,1$
bill_depth_mm	$18,3 \pm 1,2$	$15,0 \pm 1,0$
flipper_length_mm	$190,0 \pm 6,5$	$217,2 \pm 6,5$
body_mass_g	3701 ± 459	5076 ± 504

1.3.3 Les données manquantes

Le jeu de données ne contient aucune donnée manquante. Les 274 observations sont complètes pour les 7 variables. Aucun traitement d'imputation n'est donc nécessaire.

Chapitre 2

Présentation des graphiques adaptés

Nous présentons ici les graphiques descriptifs retenus pour explorer le jeu de données. Le choix du type de graphique est guidé par la nature des variables.

2.1 Pour les variables qualitatives : diagramme en bâtons

La figure 2.1 montre la répartition de la variable cible `species`. L'équilibre relatif (55 % / 45 %) est favorable à l'analyse statistique.




FIGURE 2.1 – Répartition des espèces dans le jeu de données (Adelie : 151, Gentoo : 123).

La figure 2.2 croise `island` et `species`. On constate immédiatement que les Gentoo ne sont présents que sur l'île de Biscoe, tandis que les Adelie sont répartis sur les trois îles. Ce résultat géographique sera confirmé par le test du χ^2 au chapitre 4.




FIGURE 2.2 – Répartition des espèces par île. Les Gentoo sont exclusivement présents sur Biscoe.

2.2 Pour les variables discrètes : diagramme en bâtons

La figure 2.3 croise `year` et `species`. Les proportions d'espèces sont stables d'une année à l'autre, ce qui suggère l'indépendance entre année et espèce.




FIGURE 2.3 – Répartition des espèces par année d'observation. Les proportions sont stables.

2.3 Pour les variables continues : boîtes à moustaches

La figure 2.4 présente les boîtes à moustaches des quatre variables continues, facettées par espèce. La séparation entre Adelie et Gentoo est flagrante pour les quatre variables : les boîtes ne se recouvrent quasiment pas. La longueur des nageoires (`flipper_length_mm`) présente la séparation la plus nette.




FIGURE 2.4 – Boîtes à moustaches des quatre variables continues par espèce. L’absence de recouvrement illustre la quasi-séparation entre Adelie et Gentoo.

2.4 Nuage de points et paradoxe de Simpson

La figure 2.5 constitue le graphique le plus important de cette étude. Elle montre la relation entre la longueur et la profondeur du bec, avec les droites de régression par espèce (traits pleins) et la droite de régression globale (pointillés noirs). On observe un **paradoxe de Simpson** : globalement, la corrélation est négative ($r = -0,55$), mais au sein de chaque espèce elle est positive (Adelie : $r = +0,39$, Gentoo : $r = +0,64$). L’espèce agit comme variable confondante.




FIGURE 2.5 – Paradoxe de Simpson : la corrélation entre longueur et profondeur du bec est négative globalement (pointillés) mais positive au sein de chaque espèce (traits pleins).

2.5 Pairs plot

La figure 2.6 synthétise les distributions, corrélations et séparations entre espèces en une seule image. On y retrouve la quasi-séparation pour chaque paire de variables continues.




FIGURE 2.6 – Pairs plot : distributions marginales (diagonale), nuages de points (triangle inférieur) colorés par espèce.

2.6 Matrice de corrélation

La figure 2.7 présente la matrice de corrélation de Pearson entre les variables continues, calculée sur l'ensemble des données. Les corrélations les plus fortes sont observées entre `flipper_length_mm` et `body_mass_g` ($r = 0,88$), et entre `bill_length_mm` et `body_mass_g` ($r = 0,88$). La corrélation négative entre `bill_length_mm` et `bill_depth_mm` ($r = -0,55$) est trompeuse en raison du paradoxe de Simpson.




FIGURE 2.7 – Matrice de corrélation de Pearson entre les variables continues (données globales).

Chapitre 3

Présentation des tests adaptés

Ce chapitre rappelle les fondements théoriques des tests statistiques utilisés dans l'étude.

3.1 Indépendance entre variables qualitatives : test du χ^2 d'indépendance

Pour étudier la liaison entre deux variables qualitatives (ou quantitatives discrètes avec peu de modalités), on utilise le test du χ^2 d'indépendance. On souhaite tester :

$(H_0) : X \text{ et } Y \text{ sont indépendantes}$ contre $(H_1) : X \text{ et } Y \text{ sont liées}$.

Soit aussi :

$(H_0) : P(X = u_j \text{ et } Y = v_k) = P(X = u_j) \cdot P(Y = v_k), \quad \forall (j, k) \in \{1, \dots, J\} \times \{1, \dots, K\},$
 $(H_1) : \exists (j, k) \text{ tel que } P(X = u_j \text{ et } Y = v_k) \neq P(X = u_j) \cdot P(Y = v_k).$

On estime $P(X = u_j \text{ et } Y = v_k)$, $P(X = u_j)$ et $P(Y = v_k)$ respectivement par $\frac{N_{j,k}}{n}$, $\frac{N_{j\bullet}}{n}$ et $\frac{N_{\bullet k}}{n}$.

Sous (H_0) , les différences $\frac{N_{j,k}}{n} - \frac{N_{j\bullet}}{n} \frac{N_{\bullet k}}{n}$ ne doivent être dues qu'aux fluctuations d'échantillonnage. La statistique de test est :

$$T_n = \sum_{j=1}^J \sum_{k=1}^K \frac{\left(N_{j,k} - \frac{N_{j\bullet} N_{\bullet k}}{n} \right)^2}{\frac{N_{j\bullet} N_{\bullet k}}{n}}. \quad (3.1)$$

Proposition. Si les conditions suivantes sont satisfaites : (i) n est grand, (ii) les classes constituent un système complet d'événements, (iii) les effectifs théoriques sont suffisamment importants ($\frac{N_{j\bullet} N_{\bullet k}}{n} \geq 5$ pour tout (j, k)), alors sous (H_0) :

$$T_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}, H_0} \chi^2((J-1)(K-1)).$$

Pour un test de niveau α , on rejette (H_0) quand $T_n \geq c_\alpha$ où c_α est tel que $P(\chi^2((J-1)(K-1)) \geq c_\alpha) = \alpha$.

Remarques.

1. S'il existe une classe telle que l'effectif théorique est inférieur à 5, on regroupe deux (ou plus) classes. En R : `chisq.test(V1, V2)$expected`.
 2. Si les variables n'ont que 2 modalités et qu'on ne peut pas regrouper, on utilise le test exact de Fisher (`fisher.test` en R).
 3. Le nombre de degrés de liberté est $(J - 1)(K - 1)$.
- La commande R est `chisq.test`.

3.2 Liaison entre une variable continue et une variable qualitative à 2 modalités

3.2.1 Test d'égalité d'espérances pour échantillons indépendants (test de Welch)

Considérons $X_1, \dots, X_{n_1}$, n_1 v.a. i.i.d. de loi P_X et $Y_1, \dots, Y_{n_2}$, n_2 v.a. i.i.d. de loi P_Y , avec les deux échantillons indépendants. On souhaite tester :

$$(H_0) : E(X) = E(Y) \quad \text{contre} \quad (H_1) : E(X) \neq E(Y).$$

La statistique de test de Welch est :

$$T_{n_X, n_Y} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_Y^2}{n_Y}}}, \quad (3.2)$$

avec $S_X^2 = \frac{1}{n_X - 1} \sum_{i=1}^{n_X} (X_i - \bar{X})^2$ et $S_Y^2 = \frac{1}{n_Y - 1} \sum_{i=1}^{n_Y} (Y_i - \bar{Y})^2$.

On peut montrer que sous H_0 :

$$T_{n_X, n_Y} \xrightarrow[n_X, n_Y \rightarrow +\infty]{\mathcal{L}, H_0} \mathcal{N}(0, 1).$$

On rejette H_0 quand $|T_{n_X, n_Y}| \geq u_\alpha$ où u_α est le quantile d'ordre $1 - \alpha/2$ de $\mathcal{N}(0, 1)$.

Justification théorique. La validité asymptotique de la statistique de Welch repose sur le Théorème Central Limite. Avec $n_1 = 151$ et $n_2 = 123$, l'approximation gaussienne est excellente. Le test de Shapiro-Wilk peut être mentionné pour la forme, mais à grand n il rejette la normalité sur des écarts négligeables sans que cela invalide Welch.

La commande R est `t.test(X ~ Y, var.equal = FALSE)`.

3.2.2 Test de Kolmogorov-Smirnov à 2 échantillons

Considérons $X_1, \dots, X_{n_X}$ et $Y_1, \dots, Y_{n_Y}$ deux échantillons indépendants de v.a. continues. On souhaite tester :

$$(H_0) : F_X = F_Y \quad \text{contre} \quad (H_1) : F_X \neq F_Y.$$

La statistique de test est :

$$\sqrt{\frac{n_X n_Y}{n_X + n_Y}} \sup_{x \in \mathbb{R}} \left| \hat{F}_{n_X}(x) - \hat{G}_{n_Y}(x) \right|, \quad (3.3)$$

où $\hat{F}_{n_X}(x) = \frac{1}{n_X} \sum_{i=1}^{n_X} \mathbf{1}_{X_i \leq x}$ et $\hat{G}_{n_Y}(x) = \frac{1}{n_Y} \sum_{i=1}^{n_Y} \mathbf{1}_{Y_i \leq x}$. On rejette (H_0) pour de grandes valeurs de la statistique.

La commande R est `ks.test`.

3.2.3 Test de la somme des rangs de Wilcoxon (Mann-Whitney)

Pour tester la différence de médianes entre deux groupes :

$$(H_0) : \text{Med}(Y - X) = 0 \quad \text{contre} \quad (H_1) : \text{Med}(Y - X) \neq 0.$$

La commande R est `wilcox.test`.

3.3 Liaison entre variables continues

3.3.1 Test de corrélation de Pearson

Soient $(X_1, Y_1), \dots, (X_n, Y_n)$ des couples de v.a. quantitatives i.i.d. On note ρ le coefficient de corrélation entre X_i et Y_i . On souhaite tester :

$$(H_0) : \rho = 0 \quad \text{contre} \quad (H_1) : \rho \neq 0, \quad \text{où } \rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

La statistique de test est :

$$T_n = \frac{\sum_{k=1}^n (X_k - \bar{X})(Y_k - \bar{Y})}{\sqrt{\sum_{k=1}^n (Z_k - \bar{Z})^2}}, \quad \text{où } Z_k = (X_k - \bar{X})(Y_k - \bar{Y}). \quad (3.4)$$

Sous H_0 et sous la condition $0 < E[(X_i - \mu_X)^2(Y_i - \mu_Y)^2] < \infty$, on a :

$$T_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}, H_0} \mathcal{N}(0, 1).$$

La zone de rejet est $R_{n,\alpha} = \{|T_n| > u_\alpha\}$. La commande R est `cor.test`.

3.3.2 Test d'indépendance de Kolmogorov-Smirnov

Considérons $(X_1, Y_1), \dots, (X_n, Y_n)$, n copies indépendantes d'un couple (X, Y) de v.a. continues. On souhaite tester :

$$(H_0) : X \text{ et } Y \text{ sont indépendantes} \quad \text{contre} \quad (H_1) : X \text{ et } Y \text{ ne sont pas indépendantes.}$$

La statistique de test est :

$$T_n = \sqrt{n} \sup_{s, t \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{X_i \leq s, Y_i \leq t} - F_{n,X}(s) \cdot F_{n,Y}(t) \right|, \quad (3.5)$$

où $F_{n,X}(s) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{X_i \leq s}$ et $F_{n,Y}(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{Y_i \leq t}$.

On rejette (H_0) pour de grandes valeurs de T_n . La commande R est `indepstest` (package `robustTest`).

Chapitre 4

Mise en œuvre sur le jeu de données

Ce chapitre présente les résultats des tests statistiques appliqués au jeu de données Palmer Penguins.

4.1 Test du χ^2 : species $\times$ island

On teste l'indépendance entre l'espèce et l'île à l'aide du test du χ^2 . Le tableau 4.1 présente la table de contingence observée et le tableau 4.2 les effectifs théoriques sous H_0 .

TABLE 4.1 – Table de contingence observée : species $\times$ island.

	Biscoe	Dream	Torgersen
Adelie	44	56	51
Gentoo	123	0	0

TABLE 4.2 – Effectifs théoriques sous H_0 : species $\times$ island.

	Biscoe	Dream	Torgersen
Adelie	92,0	30,9	28,1
Gentoo	75,0	25,1	22,9

Tous les effectifs théoriques sont supérieurs ou égaux à 5 (le minimum vaut 22,9). Le test du χ^2 est donc parfaitement valide et le test exact de Fisher n'est pas requis.

Résultat : $\chi^2 = 143,00$, ddl = 2, $p = 8,9 \times 10^{-32}$.

Décision : On rejette H_0 au niveau $\alpha = 5\%$. Les variables **species** et **island** sont liées. Ce résultat s'explique par le fait que les Gentoo sont exclusivement présents sur l'île de Biscoe (zéros structurels dans la table de contingence).

4.2 Test du χ^2 : species $\times$ year

On teste l'indépendance entre l'espèce et l'année d'observation.

TABLE 4.3 – Table de contingence observée : `species` $\times$ `year`.

	2007	2008	2009
Adelie	49	50	52
Gentoo	34	46	43

Les effectifs théoriques sont tous supérieurs à 5 (minimum : 37,3).

Résultat : $\chi^2 = 0,878$, ddl = 2, $p = 0,645$.

Décision : On ne rejette pas H_0 au niveau $\alpha = 5\%$. Les variables `species` et `year` sont indépendantes. L'échantillonnage n'est donc pas biaisé temporellement : les proportions d'espèces sont stables d'une année à l'autre. Ce résultat constitue un *contre-exemple* utile face aux tests hautement significatifs qui suivent.

4.3 Tests de Welch : `species` $\times$ variables continues

Pour chacune des quatre variables continues, on applique le test de Welch (`t.test` avec `var.equal = FALSE`) pour comparer les moyennes entre Adelie et Gentoo.

Justification du test : la validité asymptotique de la statistique de Welch repose sur le Théorème Central Limite. Avec $n_1 = 151$ et $n_2 = 123$, l'approximation gaussienne est excellente. Le test de Shapiro-Wilk indique quelques écarts marginaux à la normalité (par exemple $p = 0,002$ pour les nageoires des Gentoo), mais à cette taille d'échantillon ces écarts sont négligeables et n'invalident pas le test de Welch.

Les résultats sont présentés dans le tableau 4.4.

TABLE 4.4 – Résultats des tests de Welch : comparaison des moyennes par espèce.

Variable	Moy. Adelie	Moy. Gentoo	Écart	p -value	IC 95 % de l'écart
<code>bill_length_mm</code>	38,8	47,5	+8,7 mm	$3,1 \times 10^{-68}$	[8,0 ; 9,4]
<code>bill_depth_mm</code>	18,3	15,0	-3,4 mm	$1,5 \times 10^{-73}$	[-3,6 ; -3,1]
<code>flipper_length_mm</code>	190,0	217,2	+27,2 mm	$3,2 \times 10^{-99}$	[25,7 ; 28,8]
<code>body_mass_g</code>	3701	5076	+1375 g	$7,7 \times 10^{-65}$	[1260 ; 1491]

Décision : Pour les quatre variables continues, on rejette H_0 au niveau $\alpha = 5\%$. Les espèces diffèrent significativement sur toutes les mesures morphométriques. L'ampleur des écarts est considérable : les Gentoo ont un bec plus long (+8,7 mm), moins profond (-3,4 mm), des nageoires bien plus longues (+27,2 mm) et une masse corporelle nettement supérieure (+1 375 g).

Significativité versus ampleur. Avec $n = 274$ et des groupes aussi séparés, toutes les p -values sont extrêmement faibles. Ces valeurs ne mesurent pas la « force » du lien mais simplement son existence. Pour apprécier l'ampleur, on se réfère aux intervalles de confiance de la différence des moyennes et aux boîtes à moustaches sans recouvrement (figure 2.4). La variable `flipper_length_mm` présente le plus grand écart relatif et constitue la variable la plus discriminante.

4.4 Tests non paramétriques de robustesse

Pour confirmer les résultats du test de Welch sans supposer la normalité, nous appliquons le test de Mann-Whitney (Wilcoxon) et le test de Kolmogorov-Smirnov à 2 échantillons.

TABLE 4.5 – Tests non paramétriques de robustesse.

Variable	Mann-Whitney		KS 2 échantillons	
	U	p	D	p
bill_length_mm	224	$7,3 \times 10^{-44}$	0,903	$2,9 \times 10^{-59}$
bill_depth_mm	18 320	$1,3 \times 10^{-43}$	0,895	$5,1 \times 10^{-58}$
flipper_length_mm	26	$9,1 \times 10^{-46}$	0,979	$8,4 \times 10^{-75}$
body_mass_g	400	$3,0 \times 10^{-42}$	0,836	$1,0 \times 10^{-48}$

Les tests non paramétriques confirment systématiquement les conclusions du test de Welch : les deux espèces diffèrent significativement pour chaque variable morphométrique, indépendamment de toute hypothèse de normalité.

4.5 Corrélations entre variables continues et paradoxe de Simpson

Le tableau 4.6 présente les corrélations de Pearson entre les variables continues.

TABLE 4.6 – Corrélations de Pearson entre variables continues (données globales).

Paire de variables	r	p -value
bill_length $\times$ bill_depth	-0,546	$1,1 \times 10^{-22}$
bill_length $\times$ flipper_length	+0,869	$4,2 \times 10^{-85}$
bill_length $\times$ body_mass	+0,877	$1,6 \times 10^{-88}$
bill_depth $\times$ flipper_length	-0,640	$5,4 \times 10^{-33}$
bill_depth $\times$ body_mass	-0,483	$1,9 \times 10^{-17}$
flipper_length $\times$ body_mass	+0,882	$5,5 \times 10^{-91}$

Paradoxe de Simpson. Le résultat le plus remarquable concerne la paire bill_length_mm $\times$ bill_depth_mm :

- **Corrélation globale** : $r = -0,55$ ($p = 1,1 \times 10^{-22}$) — corrélation négative.
- **Corrélation intra-Adelie** : $r = +0,39$ ($p = 6,7 \times 10^{-7}$) — corrélation positive.
- **Corrélation intra-Gentoo** : $r = +0,64$ ($p = 1,0 \times 10^{-15}$) — corrélation positive.

Ce renversement de signe constitue un **paradoxe de Simpson** classique : la variable *species* agit comme variable confondante. Au sein de chaque espèce, un manchot au bec plus long a tendance à avoir un bec plus profond. Mais comme les Gentoo ont un bec long *et* peu profond par rapport aux Adelie, la tendance globale s'inverse. Ce phénomène est parfaitement illustré par la figure 2.5.

4.6 Tableau de synthèse

Le tableau 4.7 résume l'ensemble des tests réalisés.

TABLE 4.7 – Synthèse des tests statistiques ($\alpha = 5\%$).

Liaison	Test	<i>p</i> -value	Ampleur	Décision
species $\times$ island	χ^2	$8,9 \times 10^{-32}$	Gentoo = Biscoe	Liées
species $\times$ year	χ^2	0,645	Réparti	Indépendantes
species $\times$ bill_length	Welch	$3,1 \times 10^{-68}$	+8,7 mm	Liées
species $\times$ bill_depth	Welch	$1,5 \times 10^{-73}$	−3,4 mm	Liées
species $\times$ flipper_length	Welch	$3,2 \times 10^{-99}$	+27,2 mm	Liées
species $\times$ body_mass	Welch	$7,7 \times 10^{-65}$	+1 375 g	Liées

Chapitre 5

Conclusion

Cette étude du jeu de données Palmer Penguins (Adelie vs Gentoo) a permis de mettre en évidence plusieurs résultats importants à l'aide des tests statistiques du cours.

Réponse à l'objectif principal. Les quatre variables morphométriques — longueur du bec, profondeur du bec, longueur des nageoires et masse corporelle — distinguent fortement les deux espèces. Tous les tests de Welch rejettent H_0 avec des p -values inférieures à 10^{-64} , et ces résultats sont confirmés par les tests non paramétriques de Mann-Whitney et de Kolmogorov-Smirnov. La variable `flipper_length_mm` présente le plus grand écart relatif (+27,2 mm, IC à 95 % : [25,7 ; 28,8]) et constitue la variable la plus discriminante.

Géographie. La variable `island` est fortement liée à l'espèce ($\chi^2 = 143$, $p < 10^{-31}$) : les Gentoo sont exclusivement présents sur l'île de Biscoe.

Contre-exemple. La variable `year` est indépendante de l'espèce ($\chi^2 = 0,88$, $p = 0,645$), ce qui montre que l'échantillonnage n'est pas biaisé temporellement.

Paradoxe de Simpson. L'analyse des corrélations entre les dimensions du bec a révélé un paradoxe de Simpson : la corrélation globale entre longueur et profondeur est négative ($r = -0,55$) alors qu'elle est positive au sein de chaque espèce ($r = +0,39$ pour Adelie, $r = +0,64$ pour Gentoo). La variable `species` agit comme variable confondante.

Limites. La quasi-séparation complète entre les deux espèces rend les p -values peu informatives en elles-mêmes, d'où l'importance de décrire systématiquement l'ampleur des écarts via les intervalles de confiance et les moyennes par groupe. Par ailleurs, la variable `sex` n'est pas disponible dans ce jeu de données, et seules deux espèces sur trois ont été retenues.

Perspective. Ces résultats fondent naturellement un classifieur binaire. L'étape suivante serait d'utiliser une régression logistique ou une analyse discriminante linéaire pour prédire l'espèce à partir des variables morphométriques — transition naturelle vers l'apprentissage statistique, hors périmètre de ce projet.

Annexe A

Code R commenté

Nous présentons ici le code R utilisé pour reproduire l'ensemble des analyses de ce rapport.

```
# =====
# 0. Chargement et preparation des donnees
# =====
library(dplyr); library(ggplot2); library(GGally); library(knitr)
library(tidyr)

penguins <- read.csv("penguins_binary_classification.csv")
glimpse(penguins)
summary(penguins)
sapply(penguins, function(j) sum(is.na(j))) # => 0 partout

penguins <- mutate(penguins,
  species = factor(species),
  island  = factor(island),
  year    = factor(year))
attach(penguins, warn.conflicts = FALSE)

# =====
# 1. Graphiques descriptifs
# =====

# Diagramme en batons : species
ggplot(penguins, aes(species, fill = species)) +
  geom_bar() + theme_bw() +
  labs(title = "Repartition des especes", y = "Effectif")

# Diagramme en batons : island x species
ggplot(penguins, aes(island, fill = species)) +
  geom_bar(position = "dodge") + theme_bw() +
  labs(title = "Repartition par ile", y = "Effectif")

# Boxplots facettes (4 variables en 1 figure)
penguins %>%
```

```
    pivot_longer(c(bill_length_mm, bill_depth_mm,
                   flipper_length_mm, body_mass_g)) %>%
  ggplot(aes(species, value, fill = species)) +
  geom_boxplot() +
  facet_wrap(~name, scales = "free_y") + theme_bw()

# Paradoxe de Simpson
ggplot(penguins, aes(bill_length_mm, bill_depth_mm,
                     color = species)) +
  geom_point(alpha = .7) +
  geom_smooth(method = "lm", se = FALSE) +
  geom_smooth(aes(group = 1), method = "lm",
              se = FALSE, color = "black",
              linetype = "dashed") +
  labs(title = "Paradoxe de Simpson") + theme_bw()

# Pairs plot
ggpairs(penguins, columns = 3:6,
        aes(color = species, alpha = 0.6))

# =====
# 2. Tests du chi-deux
# =====

# species x island
chisq.test(species, island, correct = FALSE)
chisq.test(species, island)$expected # min = 22.9
chisq.test(species, island)$observed

# species x year
chisq.test(species, year, correct = FALSE)
chisq.test(species, year)$expected

# =====
# 3. Tests de Welch
# =====

t.test(bill_length_mm ~ species, var.equal = FALSE)
t.test(bill_depth_mm ~ species, var.equal = FALSE)
t.test(flipper_length_mm ~ species, var.equal = FALSE)
t.test(body_mass_g ~ species, var.equal = FALSE)

# Moyennes par groupe
aggregate(bill_length_mm ~ species, FUN = mean)
aggregate(bill_depth_mm ~ species, FUN = mean)
aggregate(flipper_length_mm ~ species, FUN = mean)
aggregate(body_mass_g ~ species, FUN = mean)
```

```

# =====
# 4. Tests non parametriques (robustesse)
# =====

wilcox.test(bill_length_mm ~ species)
wilcox.test(bill_depth_mm ~ species)
wilcox.test(flipper_length_mm ~ species)
wilcox.test(body_mass_g ~ species)

ks.test(
  penguins$bill_length_mm[species == "Adelie"],
  penguins$bill_length_mm[species == "Gentoo"])
# idem pour les 3 autres variables

# =====
# 5. Correlations de Pearson + paradoxe de Simpson
# =====

cor.test(flipper_length_mm, body_mass_g)
cor.test(bill_length_mm, flipper_length_mm)

# Paradoxe de Simpson
cor.test(bill_length_mm, bill_depth_mm) # global : r = -0.55
by(penguins, species, function(d)
  cor(d$bill_length_mm, d$bill_depth_mm))
# Adelie : +0.39 / Gentoo : +0.64

# =====
# 6. Tableau de synthese
# =====

res <- data.frame(
  Liaison = c("species x island", "species x year",
              "species x bill_len", "species x bill_depth",
              "species x flipper", "species x mass"),
  Test = c("Chi2", "Chi2", "Welch", "Welch", "Welch", "Welch"),
  p_value = c("9e-32", "0.64", "<1e-67", "<1e-73",
              "<1e-99", "<1e-64"),
  Ampleur = c("Gentoo=Biscoe", "reparti", "+8.7 mm",
              "-3.3 mm", "+27 mm", "+1375 g"),
  Decision = c("Liees", "Independantes",
              rep("Liees", 4)))
kable(res, caption = "Synthese des tests (alpha = 5%)")

```


Bibliographie

- [1] Horst, A. M., Hill, A. P., et Gorman, K. B. (2020). *palmerpenguins : Palmer Archipelago (Antarctica) penguin data*. R package version 0.1.0. <https://allisonhorst.github.io/palmerpenguins/>
- [2] Gorman, K. B., Williams, T. D., et Fraser, W. R. (2014). Ecological sexual dimorphism and environmental variability within a community of Antarctic penguins (genus *Pygoscelis*). *PLoS ONE*, 9(3), e90081.
- [3] Horst, A. M., Hill, A. P., et Gorman, K. B. (2022). Palmer Archipelago Penguins Data in the palmerpenguins R Package — An Alternative to Anderson’s Irises. *The R Journal*, 14(1), 244–254.